



ANÁLISE DA PERFORMANCE DESPORTIVA

QUAL O MELHOR PERÍODO DO DIA PARA TREINAR?

Realizado por:

- Lara Vaz, A88362
- Mariana Lindo, A88360
- Tiago Novais, A88397

Braga

1 de abril de 2022

Resumo

Os Ambientes Inteligentes (Aml) permitem que o ser humano interaja no mundo real de forma inteligente, discreta e não invasiva. De forma ser possível integrar os Aml no quotidiano das pessoas, são necessários sensores, cuja função é recolher diferentes tipos de dados. O estudo e análise destes dados permite obter informação que depois de processada gera conhecimento, sendo este aplicado na vida das pessoas, de forma a facilitá-la e melhorar a sua qualidade.

O principal objetivo deste trabalho é recorrer aos *smartwatches* e às *smartbands* (sensores físicos) para obter as frequências cardíacas durante e após o treino, em diferentes períodos do dia (manhã e tarde), de forma a determinar aquele em que a performance desportiva é melhor. Para tal, utilizou-se o conceito de Frequência Cardíaca de Recuperação, que corresponde à diferença entre as frequências cardíacas imediatamente após o fim do treino e 1 minuto após o fim do mesmo, sendo um indicador da performance desportiva. De modo a alcançar o objetivo foram efetuadas diversas etapas, em que numa primeira fase foi efetuada a recolha de dados através dos sensores físicos e numa segunda fase através de um sensor virtual (Google Fit). Posteriormente, foram desenvolvidas várias scripts em Python que auxiliaram no processamento dos dados recolhidos, no seu armazenamento na plataforma Adafruit IO no envio dos mesmos para a plataforma Google Sheet. No processamento e visualização dos dados recolhidos foi utilizado o Google Data Studio, que funcionou como uma interface de Business Intelligence.

Com os resultados obtidos, verificou-se que o objetivo do trabalho foi cumprido, uma vez que foi possível concluir sobre o período do dia em que cada utilizador apresentava melhor performance desportiva. Tais conclusões foram obtidas através da visualização e interpretação dos gráficos e das tabelas desenvolvidas no Google Data Studio. Para além disto, foi ainda efetuada uma análise complementar relativa ao horário de treino em que o utilizador poderia adquirir uma melhor performance desportiva.

Índice

1. Introdução.....	1
1.1. Ambientes Inteligentes para a saúde.....	1
1.2. Sensorização de Ambientes Inteligentes	2
1.2.1. Sensores Físicos.....	2
1.2.2. Sensores Virtuais.....	4
1.3. Frequência Cardíaca e Performance Desportiva.....	5
1.4. Corrida aeróbica.....	6
1.5. Motivações e Objetivos.....	7
2. Arquitetura do Sistema	9
2.1. <i>Backend</i>	9
2.1.1. Recolha de Dados e conexão ao Google Fit	9
2.1.2. Utilização da Fitness API REST.....	10
2.1.3. Armazenamento de Dados - Adafruit IO.....	15
2.1.4. Reenvio para a plataforma Google (Google Sheets).....	16
2.2. Frontend: Visualização de dados e Google Data Studio	18
3. Resultados Obtidos	21
3.1. Utilizador Lara	21
3.2. Utilizador Mariana	24
3.3. Utilizador Tiago	28
3.4. Notificação ao Utilizador.....	31
4. Reflexão Crítica e Propostas de melhoria	32
5. Auto-avaliação	33
6. Referências.....	34

Índice de Ilustrações

Figura 1. Esquema da arquitetura desenvolvida.	9
Figura 2. Esquema relativo ao fluxo de concessão implícito entre a aplicação e o Google Servers. ...	12
Figura 3. OAuth 2.0 Playground e as diferentes etapas existentes.	13
Figura 4. Segunda etapa do processo de envio de solicitações HTTP para o Google Fit.	13
Figura 5. Terceira etapa do processo de envio de solicitações HTTP para o Google Fit.	14
Figura 6. Parte dos dados presente num dos feeds do Adafruit IO.	16
Figura 7. Definição das métricas, com cálculo da média, no painel de propriedades de dados do gráfico.	18
Figura 8. Painel de propriedades de dados da série temporal.	19
Figura 9. Representação gráfica da frequência cardíaca ao longo de o dia do utilizador Tiago.	20
Figura 10. Gráfico circular representativo da percentagem de treinos realizados da parte da tarde e de manhã pelo utilizador Mariana.	21
Figura 11. Representação gráfica da frequência cardíaca ao longo dos 2 minutos após o término do treino do utilizador Lara.	22
Figura 12. Gráfico de barras representativo da frequência cardíaca de recuperação ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino do utilizador Lara.	22
Figura 13. Gráfico de barras representativo da frequência cardíaca de recuperação ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino do utilizador Mariana por horas.	23
Figura 14. Número de treinos realizados pelo utilizador Mariana por hora.	23
Figura 15. Representação gráfica da frequência cardíaca ao longo dos 2 minutos após o término do treino do utilizador Mariana.	25
Figura 16. Gráfico de barras representativo da frequência cardíaca de recuperação ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino do utilizador Mariana.	25
Figura 17. Gráfico de barras representativo da frequência cardíaca de recuperação ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino do utilizador Mariana por horas.	27
Figura 18. Número de treinos realizados pelo utilizador Mariana por hora.	27
Figura 19. Representação gráfica da frequência cardíaca ao longo dos 2 minutos após o término do treino do utilizador Tiago.	28
Figura 20. Gráfico de barras representativo da frequência cardíaca de recuperação ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino do utilizador Tiago.	29

Figura 21. Gráfico de barras representativo da frequência cardíaca de recuperação ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino do utilizador Tiago por horas.....	30
Figura 22. Número de treinos realizados pelo utilizador Tiago por hora.....	31
Figura 23. Exemplo de mockup da notificação enviada ao utilizador Tiago sobre o período do dia em que deve treinar para obter melhor performance desportiva.....	32

Índice de Tabelas

Tabela 1. Avaliação da performance desportiva a partir do valor da HHR ^{[9] [10] [11]} .	6
Tabela 2. Aplicações associadas aos dispositivos utilizados como sensores físicos.	9
Tabela 3. Cálculo da média de HRR do utilizador Tiago no instante t_0 , t_1 e t_2 de manhã e de tarde	19
Tabela 4. Valores da frequência cardíaca de repouso a cada hora do dia do utilizador Lara	24
Tabela 5. Valores da frequência cardíaca de repouso a cada hora do dia do utilizador Mariana	27
Tabela 6. Valores da frequência cardíaca de repouso a cada hora do dia do utilizador Tiago.	31

1. Introdução

1.1. Ambientes Inteligentes para a saúde

Um Ambiente Inteligente (Aml) é uma nova maneira de abordar o ambiente ao redor das pessoas, onde dispositivos com poder de computação estão distribuídos por toda a parte (ubiquidade), eventualmente incluídos em objetos, permitindo que o ser humano interaja no mundo real de forma inteligente, discreta e não invasiva. Estes ambientes preveem um mundo onde as pessoas estão cercadas por interfaces inteligentes e intuitivas incorporadas nos objetos do cotidiano ao seu redor. Essas interfaces reconhecem e respondem à presença e comportamento de um indivíduo de forma personalizada e relevante ^[2]. Neste contexto, o ambiente refere-se a qualquer espaço físico ao redor das pessoas, desde casas, prédios, ruas a um campo ou uma área no mar, por exemplo. Já a palavra inteligente, quando aplicada a ambientes, refere-se principalmente à Inteligência Artificial ^{[1] [2]}.

Atualmente, os Aml já foram aplicados em diversas áreas, como por exemplo na monitorização e assistência à saúde. Isto porque, com os novos avanços da tecnologia, são cada vez maiores as demandas do uso destas tecnologias para apoiar a qualidade de vida de indivíduos com deficiência e promover o conforto no envelhecimento, permitindo que estas pessoas possam permanecer nas suas residências por mais tempo e de forma independente. Tendo isso em consideração, o *Ulster Community Hospitals Trust* da Irlanda do Norte criou o projeto *PathFinder*, que ao equipar 3.000 residências da comunidade com sensores para monitorizar o seu bem-estar, conseguiu aumentar o nível de autonomia, independência e segurança desses indivíduos, sem comprometer a sua saúde e bem-estar ^[3].

As tecnologias Aml também podem ser usadas para melhorar a qualidade de vida de indivíduos que, de outra forma, levariam uma vida solitária em casa. Com esse objetivo, a Intel criou o *Proactive Health Group* que realiza pesquisas e desenvolvimento de tecnologias que podem aumentar a qualidade de vida dos idosos. O sistema desenvolvido utiliza sensores sem fio que examinam as interações do indivíduo com outras pessoas, ao longo do seu dia, e deste modo, fornecem informações aos cuidadores resumindo as interações sociais que o indivíduo teve em casa e oferecem conselhos sobre como melhorar esse aspeto da vida de uma pessoa ^[3].

Embora levar cuidados de saúde para as residências seja um dos maiores desenvolvimentos atuais na área dos Aml, os hospitais ainda são necessários por vários motivos, e por isso, diferentes técnicas de

Aml também são aplicadas nestes ambientes. As aplicações dos Aml em hospitais podem variar desde o aumento da segurança de pacientes e profissionais até ao acompanhamento da evolução dos pacientes após intervenções cirúrgicas ^[3].

Como último exemplo da utilização dos Aml nos hospitais, pode-se considerar a sua utilização para melhorar a experiência dos pacientes nos hospitais. Por exemplo, o *Lutheran General Hospital* em Chicago construiu o *Yacktman Children's CT Pavilion*, onde os pacientes são entretidos e auxiliados por Aml durante as suas consultas ou exames. Os pacientes podem selecionar um tópico de preferência para a sua visita e, à medida que entram no hospital, a sua identidade é lida nos seus cartões que são codificados por sensores RFID. O sistema fica então ciente da presença do paciente na unidade, e também das suas preferências, podendo adequar a iluminação e as projeções de parede/teto quando estiverem numa determinada sala. As imagens projetadas podem ser usadas para acalmar a ansiedade do paciente, mas também para o orientar. Por exemplo, se uma criança precisar de sustentar a respiração durante um exame, poderá ser mostrada uma projeção com essa ação. Isto permite que o medo da criança possa ser reduzido, pois esta terá um melhor entendimento sobre o procedimento que está prestes a realizar ^[3].

1.2. Sensorização de Ambientes Inteligentes

De forma ser possível integrar os Aml no quotidiano das pessoas são necessários sensores, que são dispositivos técnicos que monitorizam o ambiente e produzem continuamente sinais numa frequência regular ^[4]. A sua função é recolher diferentes tipos de dados, como por exemplo, sinais vitais, a voz, a temperatura ou a interação das pessoas com dispositivos como os *smartphones*. O estudo e análise destes dados permite obter informação, que depois de processada, gera conhecimento, que será aplicado na vida das pessoas, de forma a facilitá-la e melhorar a sua qualidade. Existem vários tipos de sensores, entre eles os sensores físicos e os sensores virtuais, os quais serão abordados nas próximas secções.

1.2.1. Sensores Físicos

Um sensor físico é um dispositivo que mede uma quantidade física (como a temperatura) e a converte num sinal que pode ser lido por um observador ou por um instrumento ^[5]. Um exemplo de um sensor

físico é o *beacon*, um sensor baseado em *bluetooth* com transmissores de baixo custo e de baixo consumo, que notificam os dispositivos *bluetooth* da presença de alguém. Para tal, este sensor acorda periodicamente, transmitindo um sinal BLE e depois retorna a um estado de baixo consumo de energia. Entre as várias aplicações dos *beacons* destaca-se a sua utilização para localizar médicos e enfermeiros num hospital, num momento de emergência em que seja necessária a sua presença ^[6].

Outros sensores físicos são os teclados e ratos de computador, os *smartphones* e os *smartwatches*. Estes últimos são dispositivos portáteis projetados para serem usados no pulso. Assim como os *smartphones*, estes utilizam telas sensíveis ao toque, oferecem diversas aplicações como efetuar chamadas, ler mensagens, aceder ao cronómetro, ouvir música e monitorizar sinais vitais, sendo esta uma das principais funções destes relógios e que os torna tão atrativos. É de realçar as *smartbands*, enquanto sensores são idênticas aos *smartwatches*, sendo que a única diferença é que enquanto uma *smartband* é uma pulseira com sensores que transmite dados para o *smartphone*, um *smartwatch* possui uma tela que é essencialmente uma extensão do *smartphone*, um dispositivo de pulso que permite verificar textos, e-mails e até redes sociais.

Ao nível dos dados, apesar de poder haver algumas variações de marca para marca, os *smartwatches* e as *smartbands* permitem monitorizar:

- Número de passos;
- Frequência cardíaca em bpm;
- Pressão atmosférica;
- Localização geográfica.

A partir desses dados, os utilizadores têm acesso a um conjunto de informações, fornecidas pelo próprio dispositivo, nomeadamente:

- Saturação de oxigénio em sangue arterial (SpO2), obtida através de um teste com base na respiração. Este teste é efetuado sempre que o utilizador pretender, mas não é automático;
- Sono, em que através do registo da frequência cardíaca ao longo do tempo, é possível verificar qual o tipo de sono que está a ocorrer (leve, REM, profundo) e a sua duração;

- Stress, obtido com base nas flutuações da frequência cardíaca. O resultado corresponde a um valor entre 0 e 100%, em que 1-29% é baixo stress, 30-59% é normal, de 60 a 79% é nível médio e de 80-100% é nível elevado;
- Distância percorrida e velocidade média;
- Frequência cardíaca média e frequência cardíaca de repouso;
- Calendário do ciclo menstrual.

A partir destas informações e de muitas outras que se podem obter com base nos dados recolhidos, é possível tirar partido destes sensores para a análise comportamental, sendo possível não só o utilizador monitorizar a sua própria saúde e comportamento, por exemplo, ao nível de stress e sono, mas também fornecer essas informações ao seu médico, de forma a complementar exames realizados. Deste modo, verifica-se que os *smartwatches* e as *smartbands* são sensores muito versáteis e com um custo acessível para a maioria das pessoas.

1.2.2. Sensores Virtuais

Ao contrário dos sensores físicos que reagem a um estímulo físico e transmitem o impulso resultante, os sensores virtuais são sensores de software puro que produzem sinais de forma autónoma, combinando e agregando sinais que recebem (de forma síncrona ou assíncrona) de sensores físicos ou de outros sensores virtuais ^[4].

Existem diferentes tipos de sensores virtuais, como por exemplo, o *OpenWeather* e o *AccuWeather* que são sensores virtuais para dados climatológicos e o *IQAir* e o *BreezoMeter* que são sensores para dados relativos à poluição do ar. Outro tipo de sensores virtuais muito utilizados são os que recolhem dados sobre o tráfego rodoviário, permitindo averiguar quais as estradas com maior afluência e a que horários.

Relativamente à área desportiva, existem inúmeros sensores virtuais, entre eles o Google Fit. Disponível no Android e no iOS, este compila informações de outras aplicações centradas na saúde e de rastreadores de condicionamento físico (como por exemplo as aplicações associadas aos *smartwatches* e *smartbands*), fornecendo uma visão geral das atividades diárias e semanais de

condicionamento físico e de sono dos utilizadores. O seu objetivo principal é atuar como um *personal trainer* virtual para ajudar as pessoas a alcançarem uma vida mais saudável e ativa ^[7].

1.3. Frequência Cardíaca e Performance Desportiva

A performance desportiva é a maneira pela qual a participação desportiva é medida, sendo uma mistura complexa da função biomecânica, de fatores emocionais e de técnicas de treino. Para os atletas, o desempenho desportivo está associado à busca da excelência, na medida em que estes medem os seus desempenhos como uma progressão em direção à conquista de um determinado objetivo ^[8].

Uma das formas de avaliar a performance desportiva é através da Frequência Cardíaca de Recuperação (*Heart Rate Recovery* em inglês, HRR), uma vez que esta é uma medida da rapidez com que um indivíduo retorna à sua frequência cardíaca de repouso após o exercício. Para calcular a HHR é necessário seguir os seguintes passos:

1. Registrar a frequência cardíaca imediatamente após terminar o exercício;
2. Registrar a frequência cardíaca um minuto após terminar o exercício;
3. Subtrair o número obtido no 2º passo ao número obtido no 1º passo;

Depois de se executar o 3º passo, obtém-se a HHR. Quanto maior for o resultado, mais rapidamente o coração recupera o seu ritmo normal, ou seja, mais em forma está o indivíduo. Por outras palavras, melhor é o desempenho desportivo desse indivíduo. Este método pode ser aplicado para avaliar o desempenho desportivo de um indivíduo para qualquer tipo de atividade física, de acordo com os diferentes níveis apresentados na Tabela 1 ^{[9] [10]}.

Tabela 1. Avaliação da performance desportiva a partir do valor da HHR ^[9] ^[10] ^[11].

Nível de performance desportiva	Valor de HHR (bpm)
Baixo	>12
Médio	13-25
Alto	25-30
Muito alto	30-50
Excelente	50-60

Apesar do método apresentado ser o mais comum para o cálculo da HRR, alguns autores referem que a recuperação da frequência cardíaca também pode ser medida num intervalo de 2 minutos, uma vez que entre o 1º e o 2º minuto são também registadas variações bastante abruptas na diminuição da frequência cardíaca ^[11].

1.4. Corrida aeróbica

Corridas aeróbicas são corridas onde o corpo utiliza o oxigénio como a sua principal fonte de energia. Estas consistem em corridas leves a menos de 80% da frequência cardíaca máxima do indivíduo, de tal forma que seja um ritmo a que se consiga correr infinitamente ^[9].

De acordo com a ANT+, uma instituição que segue o protocolo ANT de interoperabilidade de conceitos desportivos, a Frequência Cardíaca Máxima (MHR) é o número máximo de vezes que o coração pode bater num minuto durante um esforço total. Este valor é muito importante, pois define o limite máximo a que um indivíduo pode chegar durante o seu treino, sem colocar a sua vida em risco ^[10].

1.5. Motivações e Objetivos

Atualmente, a Indústria do Desporto tem vindo a crescer, com cada vez mais modalidades a serem exploradas e desenvolvidas. Um exemplo disso foi a adição do *Skateboarding* aos Jogos Olímpicos de 2020 em Tóquio. Aliás, o setor desportivo está hoje em dia num dos seus maiores períodos de crescimento da história, com um crescimento médio anual de 4,3% desde 2014. Verifica-se também que este setor atingiu um valor de quase US\$ 488,5 biliões em 2018, sendo esse valor atualmente estimado em mais de US\$ 500 biliões ^[12].

Este crescimento veio acompanhado de um aumento acentuado no número de pessoas que praticam atividades físicas, quer sejam atletas ou não. Isto porque, cada vez mais as pessoas estão a adotar um estilo de vida saudável, em que pretendem melhorar a sua saúde, qualidade de vida e inclusive estimularem-se e desafiarem-se a melhorar a sua performance desportiva e a atingirem resultados cada vez melhores. Para tal, as pessoas aperceberam-se da necessidade de utilizar algum dispositivo que lhes permitisse monitorizar vários parâmetros relativos à sua saúde e às atividades físicas praticadas. E foi aí que começou a aumentar o interesse pelos *smartwatches* e pelas *smartbands*, dispositivos pequenos, facilmente transportáveis, discretos e esteticamente apelativos que cumpriam estes requisitos, com um custo relativamente acessível. O interesse nestes dispositivos tem aumentado de tal forma que, segundo a *Counterpoint Research*, uma empresa especializada em análise de mercado, o mercado dos *smartwatches* e das *smartbands* cresceu 24% em 2021. Foram mais de 40 milhões de unidades vendidas somente no 4º trimestre, marcando o maior número de vendas registado num único trimestre até o momento ^[13].

Sendo cada vez mais procurados e utilizados, estes dispositivos têm evoluído muito rapidamente, apresentando cada vez mais funcionalidades e uma recolha de dados mais aprimorada. Contudo, ainda não existe nenhum dispositivo no mercado que seja capaz de prever qual o melhor período para se praticar uma determinada atividade física, de forma a se obter a melhor performance desportiva para essa pessoa e para essa atividade.

Deste modo, o principal objetivo deste trabalho é recorrer aos *smartwatches* e às *smartbands* para obter as frequências cardíacas durante e após o treino, em diferentes períodos do dia, manhã e tarde, de forma a determinar aquele em que a performance desportiva é melhor. Isto porque quanto mais tempo demorar a frequência cardíaca a estabilizar após o término do treino, mais baixa será a HHR e consequentemente pior será a performance desportiva nesse período.

Para alcançar o objetivo proposto serão efetuadas uma série de etapas, que serão descritas nas próximas secções e que envolvem o tratamento, o armazenamento, a análise, o processamento e a visualização dos dados recolhidos, numa primeira fase através dos sensores físicos (*smartwatches* e *smartbands*) e numa segunda fase através de um sensor virtual (Google Fit).

Apesar do cálculo da HRR poder ser aplicado para a avaliação da performance desportiva de qualquer tipo de atividade física, neste trabalho escolheu-se apenas considerar a avaliação da performance desportiva para a corrida aeróbica. Isto porque, com o tempo disponível para a realização do trabalho, não seria possível recolher dados suficientes de vários desportos e em diferentes períodos que permitisse tirar conclusões acerca da performance desportiva para cada desporto e período.

Além disso, a escolha da corrida também teve em consideração a logística associada à sua prática, uma vez que se pode correr em qualquer local, não sendo necessário material e sendo igualmente uma atividade física que cada um dos 3 utilizadores (elementos do grupo) conseguia praticar com facilidade. Relativamente à duração da corrida, esta foi de 15 minutos, não só por questões de logística, mas também porque se utilizou como inspiração o teste de Cooper, sendo este um teste de aptidão de corrida de 12 minutos, em que a partir da distância percorrida se avalia a aptidão aeróbica. É também importante referir que durante as diferentes corridas, cada utilizador manteve aproximadamente um ritmo constante com uma frequência aproximadamente inferior a 80% da sua Frequência Cardíaca Máxima (MHR).

2. Arquitetura do Sistema

Na Figura 1 está representada a arquitetura do sistema, onde se podem visualizar os diferentes componentes, as diferentes etapas seguidas e os softwares utilizados que deram origem ao *backend* e ao *frontend* do sistema desenvolvido. Cada uma das etapas será descrita detalhadamente nas próximas secções.

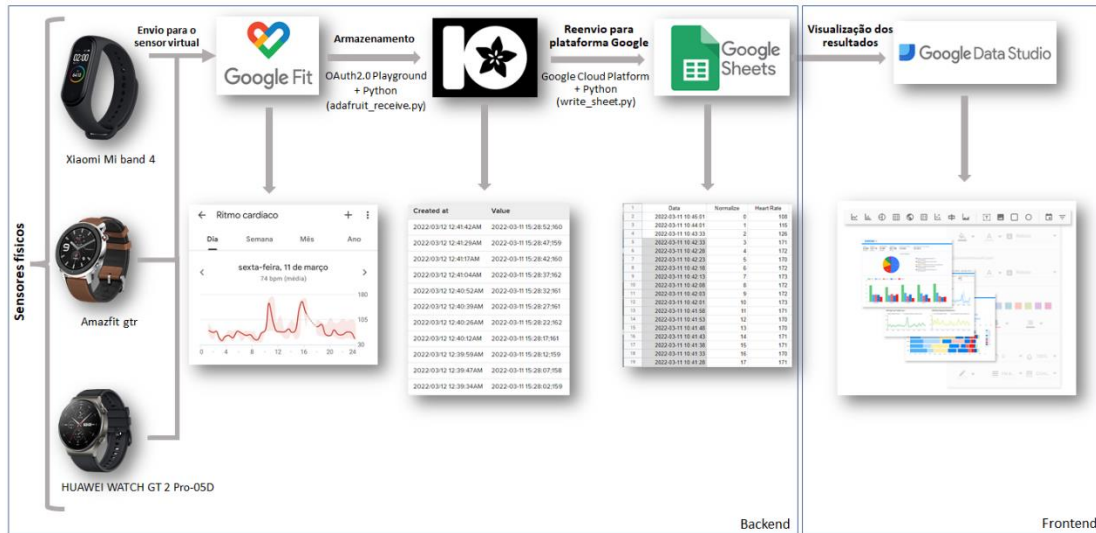


Figura 1. Esquema da arquitetura desenvolvida.

2.1. Backend

2.1.1. Recolha de Dados e conexão ao Google Fit

Como se pode verificar na Figura 1, os dados inicialmente foram recolhidos a partir de 3 sensores físicos, 2 *smartwatches* e 1 *smartband*. Todos estes registam, entre outros dados, a frequência cardíaca que depois é transmitida à respetiva aplicação Android associada ao modelo do relógio/pulseira. Na Tabela 3 estão registadas as diferentes aplicações associadas a cada dispositivo.

Tabela 2. Aplicações associadas aos dispositivos utilizados como sensores físicos.

Modelo do dispositivo	Aplicação associada
Xiaomi Mi band 4	Zepp

Amazfit gtr	<i>Zepp</i>
HUAWEI WATCH GT 2 Pro-05D	<i>Huawei Health</i>

Cada uma destas aplicações foi emparelhada com o Google Fit, que funcionou como um sensor virtual, permitindo que cada elemento tivesse associado à sua conta Google os dados recolhidos a partir do seu sensor físico. Apesar de não ser indispensável, este passo foi muito importante, pois cada aplicação tem as suas próprias políticas de dados e de segurança e estando os dados de todos os elementos presentes na sua conta do Google Fit, então, apenas se teve de lidar com os problemas relacionados com a segurança e envio dos dados para outros softwares de uma única aplicação, neste caso o Google Fit.

É também de realçar que para a conexão da aplicação *Huawei Health* com o Google Fit, foi necessária a instalação de outras aplicações complementares, como o *Huawei AppGallery*, o *Huawei AppMarket* e o *Health Sync*. Tal foi necessário, uma vez que a 16 de maio de 2019, o governo dos EUA colocou a *Huawei* na sua Lista de Entidades. Essa ação do governo proibiu todas as empresas dos EUA, incluindo o Google, de colaborar com a *Huawei*.

2.1.2. Utilização da Fitness API REST

No passo seguinte, cada um dos elementos do grupo conectou-se à Fitness API REST do Google Fit. Esta API permite ler e armazenar dados de saúde e bem-estar provenientes de uma determinada aplicação ou plataforma de *fitness*. Esta API permite também criar, obter e atualizar *data sources*. Uma *data source* representa uma fonte exclusiva de dados de um determinado sensor. Estas *data sources* são utilizadas para inserir dados de fitness numa determinada aplicação e também para fazer o *retrieval* desses mesmos dados inseridos ^[14].

Antes de ser possível utilizar esta API, foi necessário ativá-la e associá-la a um projeto. Para tal, recorreu-se à Google API Console, que é uma consola onde se podem gerir determinadas tarefas de um projeto, como gerar credenciais de API, habilitar APIs, definir os contratos de utilização da página e proceder a verificações de domínios URL. A partir desta consola, cada utilizador criou um projeto do Google Cloud Platform (GCP), que é basicamente um conjunto de definições de configuração que definem como uma determinada aplicação interage com os serviços do Google e quais recursos ela

pode usar. Tendo o projeto sido criado, foi então possível associar a Fitness API a esse projeto e ativá-la, tendo sido para isso necessário concordar com os Termos de Serviço e com a responsabilidade de cobrança da API ^[15] ^[16].

2.1.2.1. Criação de um cliente OAuth 2.0.

Na etapa seguinte, cada elemento procedeu à criação, no projeto anteriormente elaborado, das credenciais de um cliente OAuth 2.0. de uma aplicação Web. OAuth 2.0, que significa “*Open Authorization*”, é um standard projetado para permitir que um site ou aplicação aceda a recursos hospedados por outras aplicações da Web em nome de um utilizador. Desta forma, esta estrutura de autorização OAuth 2.0 permite que os utilizadores compartilhem dados específicos com uma aplicação, mantendo os seus nomes de utilizador, senhas e outras informações privadas. Por exemplo, uma aplicação pode usar o OAuth 2.0 para obter permissão dos utilizadores para armazenar ficheiros nos seus Google Drives ^[17] ^[18].

Após criadas as credenciais do cliente, é automaticamente gerado um ficheiro *client_secret* que é um ficheiro em JSON que contém diversas informações sobre o cliente, como o seu ID e o ID do projeto a que está associado. Este ficheiro é um “segredo” utilizado pelo cliente OAuth para a autenticação no servidor de autorização, sendo apenas conhecido pelo cliente OAuth e pelo servidor de autorização. O segredo do cliente deve ser suficientemente aleatório para não ser adivinhado ^[19].

2.1.2.2. Solicitações HTTP ao Google Fit

A estrutura de autorização OAuth 2.0 está assente no fluxo de concessão implícito que é projetado para que as aplicações acessem a APIs apenas enquanto o utilizador está presente nessa aplicação. Estas aplicações não são capazes de armazenar informações confidenciais. Na Figura 2 está representado um esquema que demonstra o funcionamento do fluxo de concessão implícito. Como se pode observar, a sequência de autorização começa quando a aplicação redireciona um navegador para um URL do Google. Este URL inclui parâmetros de consulta que indicam o tipo de acesso que está a ser solicitado. O Google lida com a autenticação do utilizador, a seleção da sessão e o consentimento do utilizador. O resultado é um código de autorização, que a aplicação pode trocar por um *token* de acesso e um *token* de atualização. A aplicação deve armazenar o *token* de atualização para uso futuro e usar o *token* de acesso para aceder a uma API do Google, como por exemplo, à Fitness API REST.

Passados 3600 segundos, o *token* de acesso expira e a aplicação tem de utilizar o *token* de atualização para obter um novo ^{[20] [21]}.

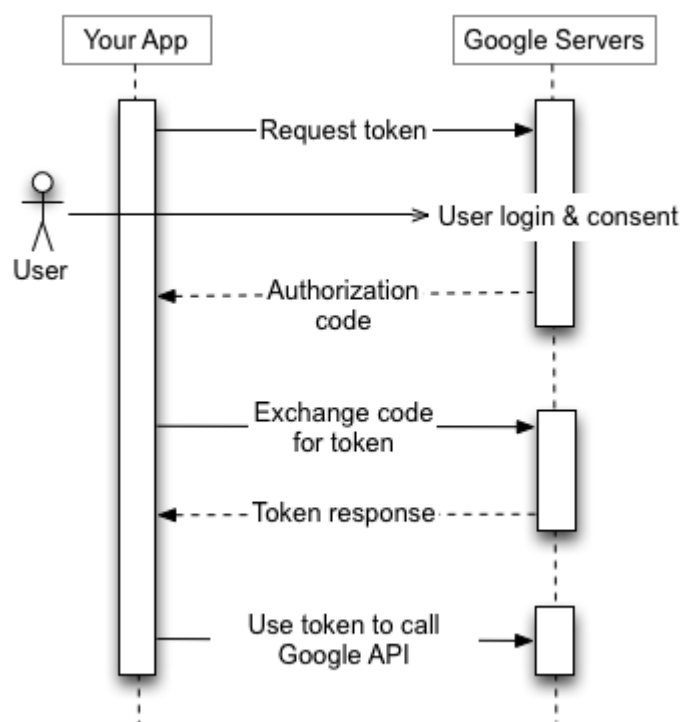


Figura 2. Esquema relativo ao fluxo de concessão implícito entre a aplicação e o Google Servers.

Estando o projeto criado e existindo um cliente desse projeto, então, é possível avançar para a próxima etapa que é a utilização do OAuth 2.0 Playground. Este é uma ferramenta para programadores que simplifica a utilização do protocolo OAuth 2.0 em APIs, pois permite experimentar algumas solicitações HTTP e observar as respostas, facilitando um posterior desenvolvimento de código. Com esta ferramenta, é então possível testar a Fitness REST API e pôr em prática o funcionamento do fluxo de concessão implícito ^[22].

Na Figura 3 está representado o OAuth 2.0 Playground, onde se pode observar a existência de 3 etapas para o envio de solicitações HTTP para uma determinada aplicação, neste caso o Google Fit. Na 1ª etapa, é necessário selecionar o escopo das APIs às quais se pretende aceder. No âmbito deste trabalho, selecionou-se a Fitness API e dentro desta escolheu-se https://www.googleapis.com/auth/fitness.heart_rate.read, já que se pretendia obter os valores de frequência cardíaca. Após se ter escolhido a API a utilizar, o utilizador tem de conceder à app Google OAuth 2.0 Playground uma autorização para aceder à sua Conta Google e ver os seus dados de

frequência cardíaca no Google Fit. Tendo sido essa autorização concedida, então, foi gerado automaticamente o código de autorização [22].

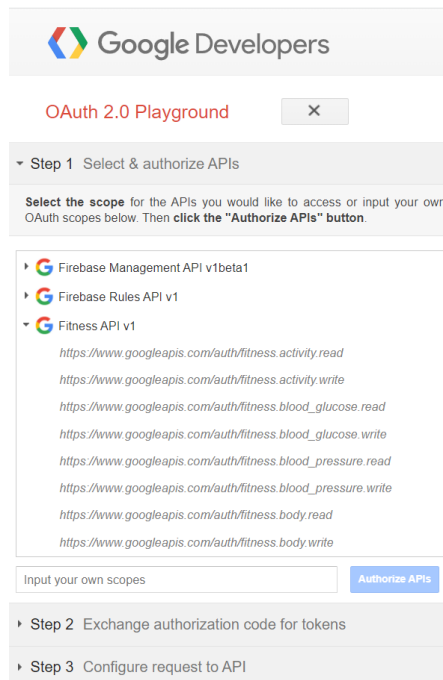


Figura 3. OAuth 2.0 Playground e as diferentes etapas existentes.

Na 2ª etapa, representada na Figura 4, procede-se a uma troca do código de autorização por um *token* de acesso, que tem de ser renovado a cada 3600 segundos, caso contrário expira e não permite o acesso ao Google Fit. Esta renovação é feita essencialmente de forma a assegurar um acesso restrito e seguro aos dados do utilizador [22].

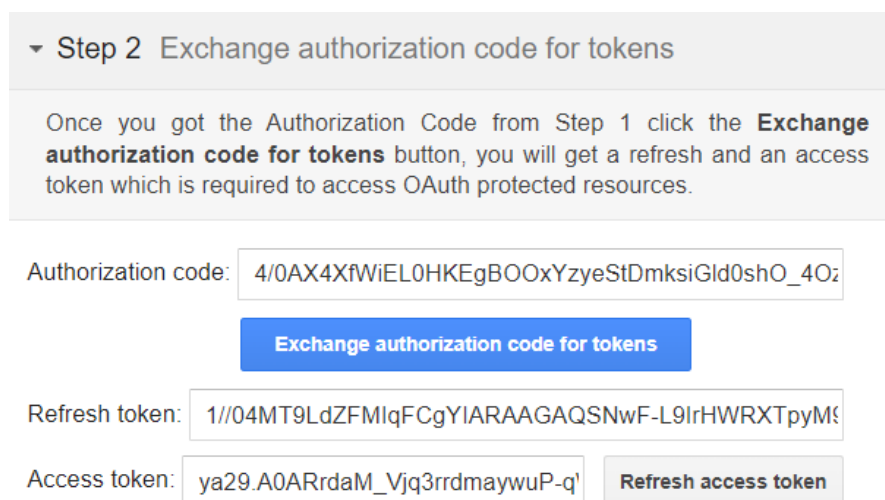


Figura 4. Segunda etapa do processo de envio de solicitações HTTP para o Google Fit.

Na 3ª e última etapa, representada na Figura 5, o utilizador constrói a sua solicitação HTTP especificando o URI, o método HTTP, cabeçalhos, o tipo de conteúdo e o *body* do *request* e envia a sua solicitação. A solicitação e a resposta aparecem no lado direito da página. Se a solicitação for bem-sucedida, a resposta mostrará a *data source* selecionada no formato JSON [22].

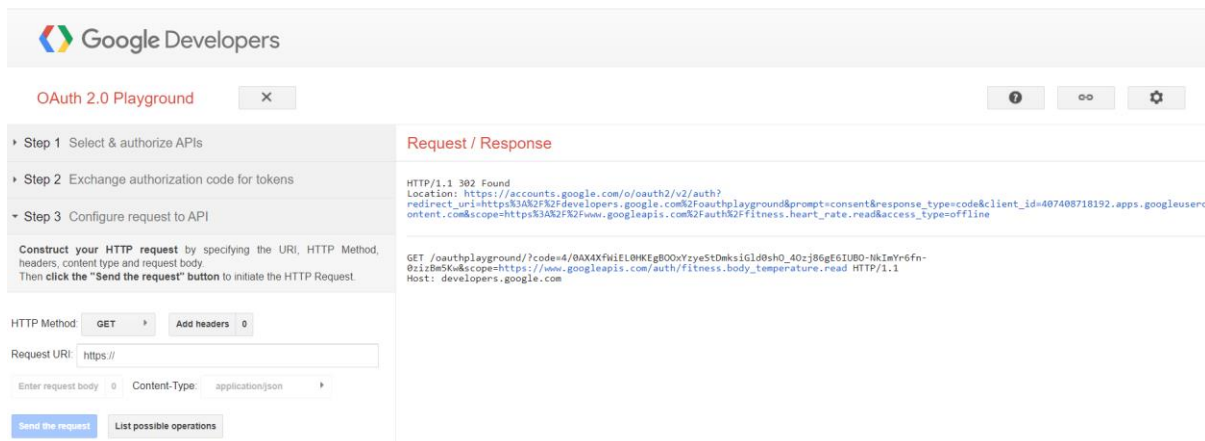


Figura 5. Terceira etapa do processo de envio de solicitações HTTP para o Google Fit.

Como foi referido anteriormente, o OAuth 2.0 Playground visa facilitar a compreensão do envio de solicitações para um posterior desenvolvimento de código. Deste modo, a terceira etapa, em vez de ser efetuada com o OAuth 2.0 Playground, foi executada através de uma script em Python (*getfit.py*, disponível em <https://github.com/MarianaLC/SmartWatch/blob/main/Ambientes%20Inteligentes/getfit.py>) em que recorrendo ao *token* de acesso gerado na 2ª etapa, efetuaram-se *requests* do tipo POST para a *data source*: <https://www.googleapis.com/fitness/v1/users/me/dataset:aggregate>, cujo ID é "derived:com.google.heart_rate.bpm:com.google.android.gms:merge_heart_rate_bpm"

Esta *data source* é específica para dados agregados, neste caso, de frequência cardíaca e é a *data source* utilizada para se ter acesso aos dados da frequência cardíaca na aplicação Google Fit. É também de realçar que, no *body* do *request*, os campos de data/hora de onde se pretendem obter os dados, estão em milissegundos. Por último, os dados obtidos foram guardados num dicionário, para posterior envio dos mesmos para o Adafruit IO [23]. Normalmente, cada um dos elementos do grupo efetuava este pedido uma vez por dia, mas os pedidos podiam ser efetuados para qualquer intervalo de tempo (por exemplo, uma semana).

2.1.3. Armazenamento de Dados - Adafruit IO

Na secção anterior, verificou-se que os dados da frequência cardíaca de cada utilizador, para um determinado período de tempo, ficaram guardados num dicionário. Neste, cada chave apresentava a forma “YYYY-MM-DDDD HH:MM:SS” e o respetivo valor era o valor da frequência cardíaca para essa data/hora em bpm.

Neste momento, o objetivo seria armazenar estes dados num único local, de forma a facilitar o seu posterior tratamento. Para tal, recorreu-se aos *feeds* da plataforma Adafruit IO. Os *feeds* são o núcleo do sistema Adafruit IO. Estes contêm metadados sobre os dados que são enviados para o Adafruit IO. Isso inclui configurações para saber se os dados são públicos ou privados, em qual licença os dados do sensor armazenados se enquadram e uma descrição geral dos dados ^[24].

De forma a transmitir cada um dados presentes no dicionário para os *feeds* do Adafruit IO, utilizou-se uma script em Python (*adafruit_receive.py*, disponível em https://github.com/MarianaLC/SmartWatch/blob/main/Ambientes%20Inteligentes/adafruit_receive.py) que considerava cada par chave-valor do dicionário e enviava-lo como uma única entrada para um determinado *feed* do Adafruit, cuja *key* está especificada no script. Para ter acesso a esse *feed*, foi utilizada a função *Client* do Adafruit IO que leva como argumentos o *username* e a *key* de um determinado utilizador do Adafruit IO e com esses parâmetros identifica o cliente, permitindo-lhe o acesso aos seus *feeds*. Tendo sido esse acesso concedido, recorreu-se à função *send* que permite enviar para um determinado *feed* do *Client* os dados que se pretender.

Para simplificar a compreensão e leitura dos dados, cada elemento do grupo criou um *feed* diferente na mesma conta do Adafruit IO, enviando para lá os seus dados, sempre que o pretendesse. Na Figura 6 está representado um exemplo de um dos *feeds* utilizados e parte dos dados existentes neste. Como se pode observar, cada valor contém uma data/hora e respetivo valor de frequência cardíaca.

<div> <div>< Prev</div> <div>First</div> </div>		<div> <div>page</div> <div>1</div> <div>of 124</div> </div>
Created at	Value	Location
2022/03/22 9:48:22PM	2022-03-22 19:39:01;73	
2022/03/22 9:48:10PM	2022-03-22 19:38:01;78	
2022/03/22 9:47:57PM	2022-03-22 19:37:01;83	
2022/03/22 9:47:45PM	2022-03-22 19:36:01;82	
2022/03/22 9:47:33PM	2022-03-22 19:32:01;81	
2022/03/22 9:47:20PM	2022-03-22 19:31:01;89	
2022/03/22 9:47:08PM	2022-03-22 19:30:01;96	
2022/03/22 9:46:55PM	2022-03-22 19:29:01;88	
2022/03/22 9:46:43PM	2022-03-22 19:21:01;97	
2022/03/22 9:46:30PM	2022-03-22 19:11:01;85	
2022/03/22 9:46:18PM	2022-03-22 19:10:01;83	

Figura 6. Parte dos dados presente num dos *feeds* do Adafruit IO.

2.1.4. Reenvio para a plataforma Google (Google Sheets)

Na secção anterior verificou-se que os dados estavam armazenados em *feeds* do Adafruit IO, um *feed* por utilizador. Estando os dados armazenados, o objetivo agora seria proceder ao tratamento e à análise desses dados, de forma a ser possível obter informações e visualizá-las numa interface de Business Intelligence. Para tal, é necessário enviar os dados do Adafruit IO para o Google Data Studio. Este último é uma ferramenta gratuita que transforma dados em painéis e relatórios informativos, fáceis de ler, fáceis de partilhar e totalmente personalizáveis ^[25].

Contudo, recentemente, o Adafruit IO e o Google Data Studio deixaram de ser parceiros, o que tornou impossível o envio direto dos dados entre as duas plataformas. Por esse motivo, foi necessário enviar os dados primeiramente para o Google Sheets, uma vez que esta plataforma consegue receber dados do Adafruit IO, funcionando como um intermediário entre o Adafruit IO e o Google Data Studio. O Google Sheets é uma plataforma com folhas de cálculo do Google que permitem destacar dados com gráficos coloridos, utilizar fórmulas, tabelas dinâmicas, formatação condicional, entre muitas outras funcionalidades ^[26].

De forma a enviar os dados do Adafruit IO para o Google Sheets foram utilizadas duas scripts em Python (*adafruit_send.py* e *write_sheets.py*, disponíveis em https://github.com/MarianaLC/SmartWatch/blob/main/Ambientes%20Inteligentes/adafruit_send.py e

https://github.com/MarianaLC/SmartWatch/blob/main/Ambientes%20Inteligentes/write_sheet.py). Na script *adafruit_send.py*, mais uma vez recorreu-se ao *Client* do Adafruit IO mas desta vez, utilizando não a função *send* mas a função *data*, que retorna os dados associados a um determinado *feed*. Para cada linha do *feed*, procedeu-se ao *split* deste campo entre a data/hora e a respetiva frequência cardíaca associada. Posteriormente, através de condições, selecionaram-se os dados que se pretendiam enviar para as *spreadsheets*. As condições permitiram definir se se pretendiam enviar dados do dia todo ou apenas de 4 minutos antes e depois do treino e do treino em si. O facto de se ter escolhido um período que para além do treino, abrangia também 4 minutos antes e depois, foi com o objetivo de verificar quer o aumento inicial da frequência cardíaca, quer a diminuição no fim do treino da mesma.

Além dessas condições, foi também criada uma variável “normalizador”, que é um contador, utilizado com o objetivo de normalizar os tempos associados aos treinos. Este foi utilizado de forma a ser possível comparar os treinos em vários horários no Google Data Studio, pois nesta plataforma, para se poderem comparar esses dados é necessário aplicar um filtro para analisar as informações em conjunto. Tendo os treinos horários diferentes, não existia um parâmetro comum entre eles, pelo que com o normalizador, todos os treinos apresentavam o mesmo tempo, numa escala de 0 até n, em que 0 é o fim do treino e n é o 4º minuto após o fim do treino.

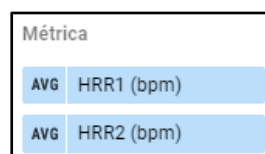
Estando os dados que se pretendem enviar selecionados, cada conjunto (data/hora, normalizador, frequência cardíaca) constitui uma lista de 3 elementos, que por sua vez, também constitui um elemento de uma outra lista. Esta última é, portanto, uma lista de listas, composta por vários elementos da forma [data/hora, normalizador, frequência cardíaca].

Já na script *write_sheet.py*, utilizou-se a função *build* do módulo *googleapiclient.discovery*, que permite construir um recurso para interagir com uma API, neste caso um serviço do Google Sheets associado às credenciais (*client_secret.json*) de uma conta Google. Mais uma vez, para facilitar o tratamento e a análise de todos os dados, optou-se por deixar os dados todos em *spreadsheets* associadas à conta Google de um único utilizador, em vez de existirem várias *spreadsheets* associadas a cada um dos utilizadores. Tendo sido o serviço criado, efetuou-se um *request* à Google Sheets API, de forma a fazer o update da *spreadsheet*, adicionando-lhe todos os valores presentes na lista obtida na script *adafruit_send.py*.

2.2. Frontend: Visualização de dados e Google Data Studio

Para a representação dos resultados obtidos foi necessário selecionar um conjunto de pontos do *dataset* recolhido e o tipo de gráficos que se adequava melhor ao contexto do problema. Como referido anteriormente, a Frequência Cardíaca de Recuperação é medida com base no instante em que o treino termina (t_0), bem como 1 minuto após o momento do término (t_1) ou 2 minutos após o mesmo (t_2). Assim procedeu-se à análise das frequências cardíacas nestes instantes de tempo. Com estes instantes de tempo já normalizados foram utilizados dois métodos para a avaliação da performance desportiva de cada utilizador tanto de manhã, como da parte da tarde.

O primeiro método consistiu em calcular a diferença entre os valores de frequência cardíaca em t_0 e em t_1 para cada treino efetuado, distinguindo os realizados na parte da manhã dos realizados na parte da tarde. De seguida, procedeu-se ao cálculo da média desses valores para ambos os casos, selecionando a opção 'AVG' disponibilizada no Google Data Studio para o efeito (Figura 7). O mesmo foi feito para os instantes t_0 e t_2 . Deste modo, obtiveram-se as Frequências Cardíacas de Recuperação Médias ao fim do 1º minuto (HRR1) e ao fim do 2º minuto (HRR2). O gráfico escolhido para a visualização deste primeiro método de avaliação foi do tipo gráfico de barras. Este está representado na Secção 3 e através da sua análise é possível comparar de forma clara e objetiva as Frequências Cardíacas de Recuperação Médias, HRR1 e HRR2, entre o período da manhã e de tarde, para cada utilizador. Como referido anteriormente, quanto maior o valor de HRR, maior a performance desportiva alcançada nesse período do dia.



Métrica	
AVG	HRR1 (bpm)
AVG	HRR2 (bpm)

Figura 7. Definição das métricas, com cálculo da média, no painel de propriedades de dados do gráfico.

Para o segundo método de avaliação foi escolhido um gráfico do tipo série temporal, representado na Secção 3, que mostra a dimensão de tempo no eixo X (eixo horizontal) e a escala da Frequência Cardíaca Média no eixo Y (eixo vertical). As métricas individuais são representadas como uma série de pontos de dados (também chamados de "marcadores") entre os dois eixos ^[27]. Neste método de avaliação procedeu-se à construção de uma reta de regressão linear, de forma a identificar o declive da reta que melhor se adequa aos pontos recolhidos em t_0 , t_1 e t_2 , sendo o declive dessa reta tanto

maior quanto maior for a HHR. Para isso, foi calculada a média das frequências cardíacas de cada treino, em cada um desses instantes, como representado na Tabela 3 na coluna Frequência Cardíaca Média. A partir desse conjunto de dados foram então construídas as retas de regressão linear quer para a manhã quer para a tarde, através da seleção da opção 'Linear' (Figura 8) para a linha de tendência da série temporal, no Google Data Studio. Com estes gráficos, foi possível visualizar as retas que melhor se ajustam à diminuição das Frequências Cardíacas Médias de t_0 a t_2 na parte da manhã e de tarde, e consequentemente avaliar qual o período que apresenta um maior declive entre os instantes t_0 e t_2 considerados.

Tabela 3. Cálculo da Frequência Cardíaca Média do utilizador Tiago nos instantes t_0 , t_1 e t_2 de manhã e de tarde.

Dias de Treino (Tarde)								
Recuperação	t	10/mar	15/mar	17/mar	21/mar	22/mar	23/mar	Frequência Cardíaca Média
2		149	93	119	125	92	104	114
1		159	130	125	158	122	163	143
0		160	165	163	163	167	168	164
Dias de Treino (Manhã)								
Recuperação	t	18/mar	19/mar	20/mar	25/mar	26/mar	Frequência Cardíaca Média	
2		101	135	143	150	109	128	21,49
1		159	165	156	164	148	158	6,88
0		163	167	160	165	161	163	2,86

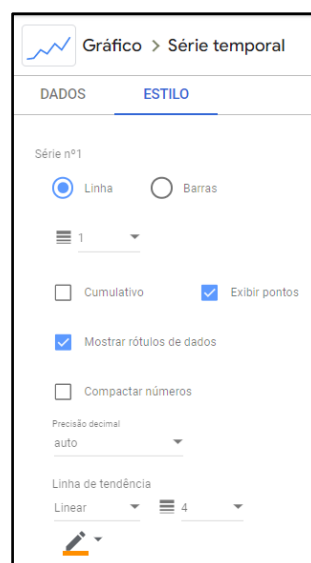


Figura 8. Painel de propriedades de dados da série temporal.

O principal objetivo da utilização de mais do que um método de avaliação foi reforçar a veracidade dos resultados e permitir uma visualização mais variada dos resultados.

Para além dos gráficos anteriormente referidos, também foram escolhidos outros gráficos e tabelas para integrarem a estrutura do *dashboard*. Assim, optou-se por acrescentar outra série temporal para demonstrar a variação da frequência cardíaca de cada utilizador ao longo de um dia inteiro (escolhido aleatoriamente), de modo a se perceber melhor o perfil do utilizador e o seu ritmo de vida. Nestes gráficos é perfeitamente visível a existência de um pico de frequência cardíaca, correspondendo ao período em que ocorreu o treino. Apesar de ser possível tirar outras conclusões sobre este tipo de gráficos, nomeadamente o stress do indivíduo e a sua Frequência Cardíaca de Repouso, neste trabalho não foi efetuada uma análise relativa a estes parâmetros, devido à falta de tempo para recolher dados que permitissem aferir sobre, por exemplo, as consequências de um dia stressado ou com menos horas de sono na performance desportiva. Para além deste gráfico, foi utilizado ainda um gráfico circular para representar a percentagem de treinos realizados na parte da manhã e na parte de tarde. A título de exemplo, apresentam-se nas Figuras 9 e 10 os gráficos correspondentes a um dos utilizadores.

Após terem sido obtidos os resultados da performance de cada utilizador de manhã e de tarde, procedeu-se a uma análise da sua performance em horas específicas do dia, com o objetivo de se perceber qual seria o melhor horário para o utilizador treinar. Os gráficos serão apresentados na secção seguinte.



Figura 9. Representação gráfica da frequência cardíaca ao longo do dia do utilizador Tiago.




Figura 10. Gráfico circular representativo da percentagem de treinos realizados da parte da tarde e de manhã pelo utilizador Mariana.

3. Resultados Obtidos

Os resultados obtidos serão apresentados nas secções seguintes (Secção 3.1, 3.2 e 3.3), com a apresentação dos gráficos anteriormente mencionados.

3.1. Utilizador Lara

Relativamente ao utilizador Lara, foi possível concluir que a melhor performance desportiva é obtida na parte da manhã, uma vez que pelo gráfico da regressão linear (Figura 11), o módulo do declive da reta de ajuste linear representada a azul (40 batimentos) é maior do que o módulo do declive da reta obtida para os treinos realizados da parte da tarde, representada a laranja (37 batimentos). Tendo em conta que o declive dessa reta é tanto maior quanto maior for a HHR, então, de manhã o utilizador Lara apresenta uma recuperação mais rápida da sua frequência cardíaca quando comparada com a recuperação no período da tarde. O mesmo se verificou com o gráfico de barras (Figura 12) em que os valores de HRR1 e HRR2 são maiores no período da manhã, tanto no 1º minuto a seguir ao término do treino, como dois minutos após o mesmo, respetivamente. No entanto, os gráficos permitem afirmar que a diferença de performance desportiva obtida nos dois períodos do dia (manhã e tarde) não é muito significativa. Verificou-se ainda que o valor da Frequência Cardíaca de Recuperação Média no 1º minuto foi de 27 bpm o que corresponde, segundo a Tabela 1 da Secção 1.3, a um nível 'Alto' de performance desportiva. Por outro lado, na parte da tarde, o HRR1 foi de 18 bpm, o que corresponde a um nível 'Médio' de performance desportiva.

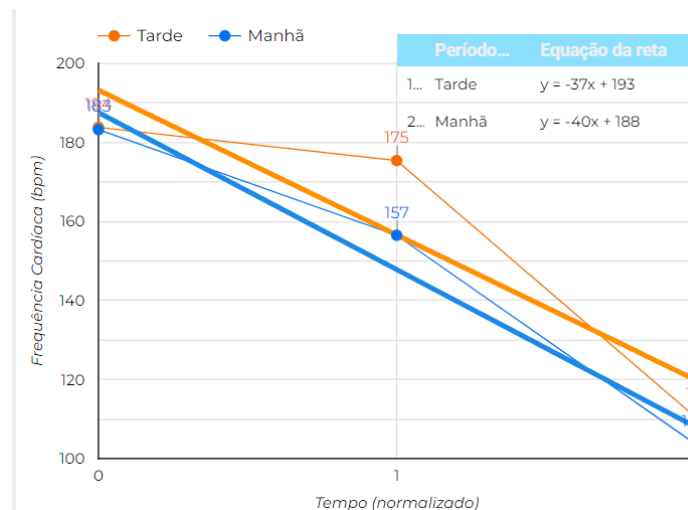


Figura 11. Representação gráfica da Frequência Cardíaca Média ao longo dos 2 minutos após o término do treino do utilizador Lara.

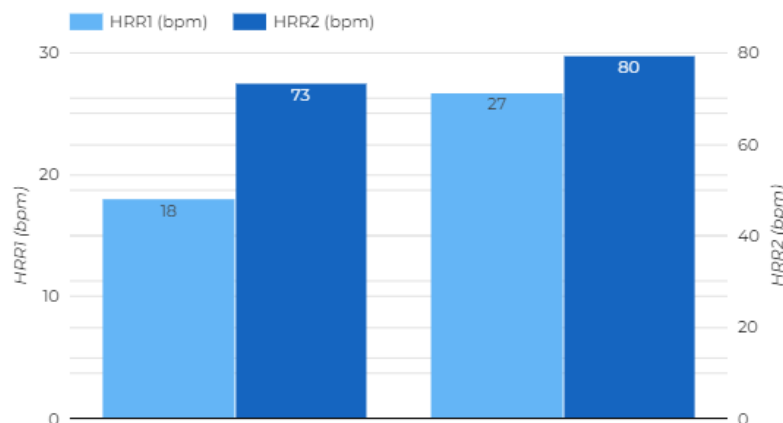


Figura 12. Gráfico de barras representativo da Frequência Cardíaca de Recuperação Média ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino do utilizador Lara.

Relativamente aos gráficos construídos para análise do melhor horário de treino, verificou-se por observação da Figura 13 e da Tabela 4, que quando o utilizador Lara treina às 11h a sua performance desportiva é melhor em comparação com outros horários, especialmente em comparação com os da parte da tarde, uma vez que a sua HRR média ao fim de 1 minuto é muito superior quando comparada com outros horários. Tal resultado vai de encontro à conclusão já retirada em relação à performance desportiva em função do período do dia em que o treino foi realizado, uma vez que o utilizador Lara obteve melhor performance desportiva nos treinos realizados da parte da manhã. Denote-se que o número de treinos realizados por hora influencia os resultados obtidos, e no caso deste utilizador a maioria dos treinos foi realizado apenas uma vez em cada hora, à exceção das 18h em que foram realizados quatro treinos na totalidade, como se pode verificar na Figura 14.

Por outro lado, analisando apenas os valores de HRR2, verificou-se que o melhor horário de treino seria às 10h da manhã e não às 11h como se obteve com a análise dos resultados do HRR1. Contudo,

é de realçar que este resultado do HRR2 não é tão relevante para a determinação do melhor horário de treino, uma vez que este valor diz respeito a uma recuperação mais tardia, entre o 1º e o 2º minuto, não correspondendo a uma recuperação tão rápida e acentuada como o HRR1 bastante elevado que se verificou às 11h. Ainda assim, os resultados baseados no horário específico em que o utilizador Lara obtém uma melhor performance não são tão claros e objetivos como os obtidos para o melhor período de treino. Para resolver este problema, deveriam ter sido recolhidos e analisados mais dados de treino, o que não foi possível devido às limitações de tempo do projeto.

Por último, é importante referir que os resultados obtidos de facto correspondem à realidade, uma vez que o utilizador Lara de facto prefere treinar de manhã, pois sente-se com mais energia e disposição.




Figura 13. Gráfico de barras representativo da Frequência Cardíaca de Recuperação Média ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino, por horas, do utilizador Lara.



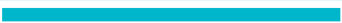


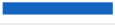







Figura 14. Número de treinos realizados por hora pelo utilizador Lara.

Tabela 4. Valores da Frequência Cardíaca de Recuperação Média ao fim de 1 e 2 minutos, a cada hora do dia do utilizador Lara.

	Hora (h)	HRR1 (bpm) +	HRR2 (bpm)
1.	11		
2.	18		
3.	10		
4.	09		
5.	16		

1-7/7 < >

3.2. Utilizador Mariana

Relativamente ao utilizador Mariana, foi possível concluir que este obtém uma melhor performance desportiva na parte da tarde, uma vez que pelo gráfico da regressão linear (Figura 15) o módulo do declive da reta, representada a laranja, é maior (37 batimentos) em comparação com o módulo do declive da reta da Frequência Cardíaca Média obtida para os treinos realizados da parte da manhã, representada a azul (27 batimentos). Isto significa que, em média, nos 2 minutos após o término do treino a frequência cardíaca diminui 10 batimentos a mais na parte da tarde do que relativamente ao período da manhã, o que se traduz numa maior Frequência Cardíaca de Recuperação e consequentemente uma melhor performance desportiva. O mesmo se verificou com o gráfico de barras (Figura 16) em que ambos os valores de HRR1 e HRR2 são superiores no período da tarde. Verificou-se ainda que o valor da Frequência Cardíaca de Recuperação Média no primeiro minuto foi de 36 bpm o que corresponde, segundo a Tabela 1 na Secção 1.3, a um nível 'Muito Alto' de performance desportiva. Já no período da manhã, esse valor foi de 28 bpm, o que apenas corresponde a um nível 'Alto' de performance desportiva.




Figura 15. Representação gráfica da Frequência Cardíaca Média ao longo dos 2 minutos após o término do treino do utilizador Mariana.

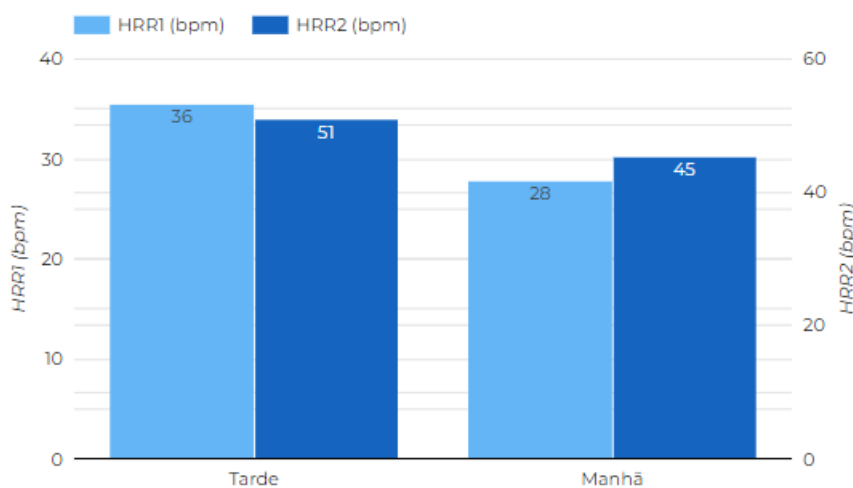


Figura 16. Gráfico de barras representativo da Frequência Cardíaca de Recuperação Média ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino do utilizador Mariana.

Relativamente aos gráficos realizados para a análise do horário específico de treino, verificou-se que quando o utilizador Mariana treina às 16h a sua performance desportiva é claramente melhor em comparação com outros horários, especialmente em comparação com os da parte da manhã, como se pode confirmar pela análise tanto do HRR1, como do HRR2, no gráfico da Figura 17 e na Tabela 5. Tal resultado vai de encontro à conclusão já retirada em relação à performance desportiva em função

do período do dia em que o treino foi realizado, uma vez que o utilizador Mariana obteve melhor performance desportiva nos treinos realizados da parte da tarde.

Comparando os valores de HRR1 e HRR2 representados na Figura 17, verificou-se que a Frequência Cardíaca de Recuperação no 1º minuto após o término (t_1) do treino realizado às 14h, apresenta um valor muito baixo comparativamente ao de HRR2. Isto significaria que a frequência cardíaca de t_1 para t_2 teria sofrido uma queda abrupta, de 54 bpm, no entanto, isto não se verifica para os restantes horários, em que a diferença entre HRR1 e HRR2 nunca é tão acentuada, sendo no máximo 25 bpm no horário do meio-dia. Desta forma, elimina-se a hipótese desta descida abrupta estar associada à performance desportiva do utilizador neste horário de treino, pois trata-se de um caso isolado. Além disso, analisando o gráfico de barras da Figura 18, verifica-se que apenas foi realizado um único treino às 14h, pelo que a credibilidade dos valores da amostra recolhida durante esse treino é muito baixa. Deste modo, é muito provável que neste treino tenha ocorrido uma falha no registo da frequência cardíaca pelo *smartwatch*. Possíveis causas para esta situação poderão ser mau contacto com a pele ou transpiração.

Neste caso, verificou-se mais uma vez que o curto período de tempo em que o estudo foi feito limitou a qualidade dos resultados, uma vez que para muitos horários de treino apenas existe uma única amostra de valores.

Por último, é de realçar que na realidade o utilizador Mariana prefere treinar à tarde, em particular a meio da tarde, pois este é um período distanciado das refeições principais e consequentemente, o utilizador sente-se mais apto a treinar.

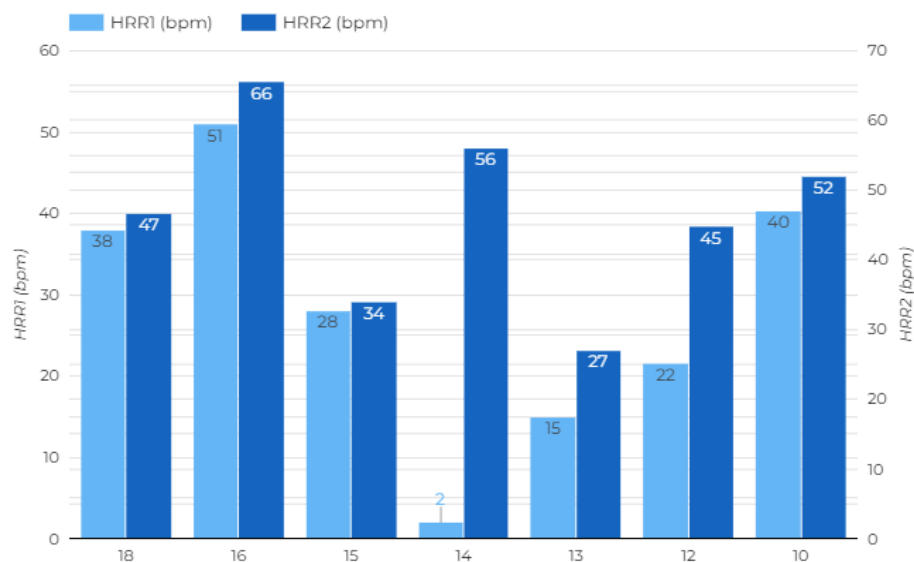


Figura 17. Gráfico de barras representativo da Frequência Cardíaca de Recuperação Média ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino por horas do utilizador Mariana.




Figura 18. Número de treinos realizados por hora pelo utilizador Mariana.

Tabela 5. Valores da Frequência Cardíaca de Recuperação Média ao 1º e 2º minutos, a cada hora do dia do utilizador Mariana.

	Hora (h)	HRR1 (bpm)	HRR2 (bpm)
1.	16	51	66
2.	10	40	52
3.	18	38	47
4.	15	28	34
5.	12	22	45

3.3. Utilizador Tiago

De acordo com os resultados obtidos, o utilizador Tiago apresenta uma melhor performance desportiva na parte da tarde, uma vez que pelo gráfico da regressão linear (Figura 19) o módulo do declive da reta, representada a laranja (25 batimentos) é superior em comparação com o módulo do declive da reta da Frequência Cardíaca Média obtida para os treinos realizados da parte da manhã, representada a azul (18 batimentos). Tendo em conta que o declive dessa reta é tanto maior quanto maior for a HHR, então, de tarde o utilizador Tiago apresenta uma recuperação mais rápida da sua frequência cardíaca quando comparada com a recuperação no período da manhã. O mesmo se verificou com o gráfico de barras (Figura 20) em que os valores de HRR1 e HRR2 são consideravelmente superiores no período da tarde, tanto no minuto a seguir ao término do treino, como dois minutos após o mesmo, respetivamente. Verificou-se ainda que o valor da Frequência Cardíaca de Recuperação Média no primeiro minuto foi de 19 bpm o que corresponde, segundo a Tabela 1 na Secção 1.3., a um nível 'Médio' de performance desportiva. Por outro lado, na parte da manhã, o valor de HRR1 é 5 bpm corresponde a um nível 'Baixo' de performance desportiva.

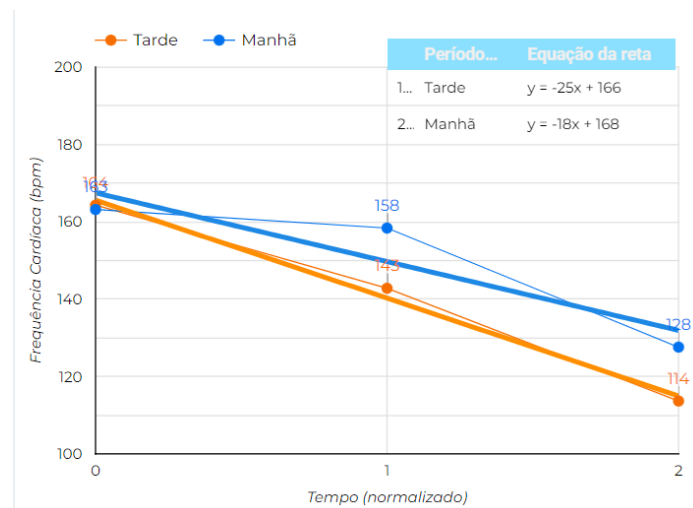


Figura 19. Representação gráfica da Frequência Cardíaca Média ao longo dos 2 minutos após o término do treino do utilizador Tiago.




Figura 20. Gráfico de barras representativo da Frequência Cardíaca de Recuperação Média ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino do utilizador Tiago.

Relativamente aos gráficos e tabelas construídos para a análise do horário específico de treino, pela observação da Figura 21 e da Tabela 6, verificou-se que quando o utilizador Tiago treina às 16h a sua performance desportiva é superior em comparação com outros horários, especialmente da parte da manhã, uma vez que o valor de HRR1 é consideravelmente superior. No entanto, ao analisar o valor de HRR2 para o mesmo horário verifica-se que existem outros horários de treino em que o utilizador obteve valores mais elevados de Frequência Cardíaca de Recuperação, como é o caso das 17h, das 13h e das 18h. Desta forma, no caso do utilizador Tiago não é possível concluir de forma clara e objetiva que existe um horário específico de treino em que o mesmo poderá obter melhor performance desportiva. Contudo, é de realçar que este resultado do HRR2 não é tão relevante para a determinação do melhor horário de treino, uma vez que este valor diz respeito a uma recuperação mais tardia, entre o 1º e o 2º minuto, não correspondendo a uma recuperação tão rápida e acentuada como o HRR1 bastante elevado que se verificou às 16h. Ainda assim, tal resultado vai de encontro à conclusão retirada na análise feita, anteriormente, à performance desportiva em função do período do dia em que o treino foi realizado. Isto porque os horários em que o utilizador apresenta quer valores maiores de HRR1, quer de HRR2 são horários de treino da parte da tarde.

Para o utilizador Tiago é também muito importante realçar o facto de que existe uma grande discrepância entre os valores de HRR1, que varia de 1 bpm a 38 bpm. Além disso, para o treino realizado às 17h, verificou-se que a Frequência Cardíaca de Recuperação no 1º minuto após o término (t_1) do treino apresenta um valor muito baixo comparativamente ao de HRR2. Isto significaria que a frequência cardíaca de t_1 para t_2 teria sofrido uma queda abrupta, de 59 bpm, no entanto, isto não se

verifica para os restantes horários, em que a diferença máxima entre HRR1 e HRR2 é de 39 bpm às 13h. Desta forma, elimina-se a hipótese desta descida abrupta estar associada à performance desportiva do utilizador neste horário de treino. Analisando o gráfico de barras da Figura 22, concluiu-se que foi realizado apenas um único treino às 17h, pelo que a credibilidade dos valores da amostra recolhida durante esse treino realizado a essa hora também é limitativa.

Deste modo, é muito provável que neste horário tenha ocorrido uma falha no registo da frequência cardíaca pelo *smartwatch*. Mais uma vez, verificou-se que o curto período de tempo em que o estudo foi feito teve influência na qualidade dos resultados obtidos.

Por último, é de realçar, que há semelhança do que ocorreu com o utilizador Mariana, o utilizador também prefere treinar à tarde, em particular a meio da tarde, pois o utilizador normalmente acorda mais tarde, descrevendo-se como mais produtivo e ativo da parte da tarde.




Figura 21. Gráfico de barras representativo da Frequência Cardíaca de Recuperação ao 1º minuto (HRR1) e ao 2º minuto (HRR2) após o término do treino por horas do utilizador Tiago.

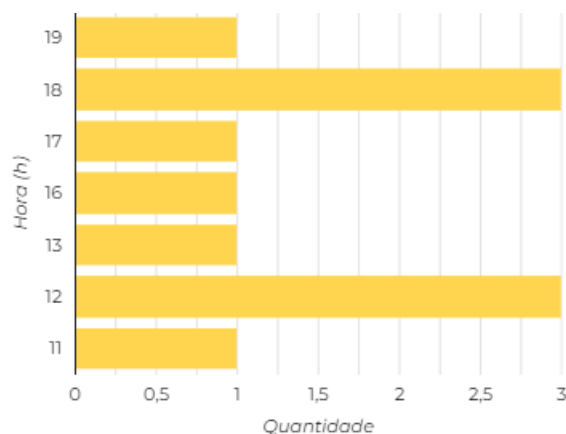


Figura 22. Número de treinos realizados por hora pelo utilizador Tiago.

Tabela 6. Valores da Frequência Cardíaca de Recuperação Média ao fim do 1º e 2º minutos, a cada hora do dia do utilizador Tiago.

	Hora (h)	HRR1 (bpm)	HRR2 (bpm)
1.	16	2.5	2.0
2.	18	1.8	2.2
3.	13	1.2	2.5
4.	17	0.5	3.0
5.	12	0.3	1.8

1-7/7 < >

3.4. Notificação ao Utilizador

De forma a exemplificar uma possível notificação enviada ao utilizador, foi realizado um *mockup* representado na Figura 23. Este consiste numa mensagem enviada ao utilizador, numa situação real e integrada numa aplicação de *fitness*, como por exemplo a Google Fit, de forma a informar o utilizador sobre qual o período do dia em que deveria treinar, de forma a maximizar a sua performance desportiva e, desta forma, alcançar mais rapidamente os seus objetivos.



Figura 23. Exemplo de *mockup* da notificação enviada ao utilizador Tiago sobre o período do dia em que deve treinar para obter melhor performance desportiva.

4. Reflexão Crítica e Propostas de melhoria

O objetivo principal do estudo foi cumprido com sucesso, uma vez que para cada um dos utilizadores foi possível aferir sobre qual seria o melhor período do dia para treinar, de maneira a obter uma melhor performance desportiva. A aquisição de dados através de sensores permitiu criar um serviço de notificação personalizado e adequado a cada utilizador. Com a análise destes dados conseguiu-se gerar conhecimento, personalizado a cada utilizador, que pode ser aplicado na vida dos utilizadores, de forma a potenciar a obtenção de melhores desempenhos desportivos.

Relativamente às limitações do trabalho, destaca-se o facto dos utilizadores não obterem resultados imediatos quanto ao melhor período do dia em que o treino deve ser integrado. Isto porque, para ser possível este tipo de previsão, é necessário recolher e analisar previamente alguns dados para então depois ser possível concluir acerca do melhor período para treinar. Outra limitação prende-se com o facto de os resultados obtidos serem também condicionados pelos dados fornecidos pelo *smartwatch* ou *smartband*, e por isso, erros na aquisição de dados obtidos por mau contacto, incorreta colocação do sensor ou até transpiração excessiva durante o treino, poderão afetar os resultados.

Da mesma forma, existem muitas outras variantes que não foram tidas em conta por questões de tempo, mas que deveriam ter sido consideradas para se obterem resultados mais precisos, como a

prática de jejum antes do treino, o stress, o consumo de cafeína, a utilização de medicamentos e de suplementos, a qualidade do sono, entre outros. Além disso, apesar de teoricamente a Frequência Cardíaca de Recuperação poder ser utilizada como indicador de performance desportiva para qualquer desporto, este resultado não pôde ser comprovado, uma vez que neste estudo apenas foi considerado um tipo de exercício físico, neste caso a corrida aeróbica.

Como referido anteriormente, devido à falta de tempo para adquirir dados, também não foi possível obter uma grande quantidade de dados para treinos em diferentes horários, o que comprometeu a previsão do melhor horário de treino para cada utilizador. Por este motivo, neste trabalho, a previsão do melhor horário de treino apenas permitiu reforçar as conclusões obtidas na análise do melhor período do dia para treinar, se de manhã ou de tarde.

Como outras propostas de melhoria, sugere-se a aplicação de modelos de Machine Learning que com base no histórico de dados de frequência cardíaca do utilizador, poderiam prever com precisão o melhor horário de treino, para cada desporto e tendo em conta se o indivíduo estaria stressado ou mais calmo. Sugere-se ainda a utilização de modelos de Deep Learning, que também com base num histórico de dados de valores de frequência cardíaca do utilizador, poderiam sugerir diferentes tipos de treinos de acordo com o dia da semana, com o histórico de treino e com o estado de espírito do indivíduo, de forma a não treinar sempre os mesmos músculos e a escolher treinos que maximizassem a performance desportiva de acordo com os horários em que o indivíduo tivesse disponibilidade. Por último, seria também interessante monitorizar constantemente os valores de frequência cardíaca do indivíduo e sempre que estes valores saíssem muito da gama de valores normais desse indivíduo, alertá-lo, de forma a este poder consultar-se com um médico.

Em suma, todos estes fatores a ter em conta poderão ser integrados e avaliados num estudo futuro, de forma a melhorar a precisão dos resultados obtidos e alargar o universo em que este tipo de conhecimento pode ser útil. Isto porque a Frequência Cardíaca de Recuperação pode ser utilizada não só para avaliar a performance desportiva, mas também para monitorização da saúde cardíaca.

5. Auto-avaliação

O trabalho foi realizado por todos os elementos do grupo de forma equitativa. Cada um fez parte do estudo como *user* e *developer* do sistema. O grupo considera que todos os objetivos propostos foram cumpridos, conscientes de que o curto espaço de tempo em que o estudo foi feito limitou a qualidade

dos resultados obtidos, mas também sabendo que com mais tempo poderiam ter sido adotadas mais abordagens para melhorar os resultados. Ainda assim, a implementação de um sistema inteligente capaz de recolher e monitorizar leituras de sensores físicos e virtuais no domínio da análise comportamental foi cumprida com sucesso.

6. Referências

- [1] Maes, P., Schneiderman, B., "Direct Manipulation vs. Interface Agents: a Debate." Interactions, 4 Number 6, ACM Press, 1997.
- [2] Russell S, Norvig P., "Artificial Intelligence: A Modern Approach (Second Edition)". New York: Prentice Hall, 2003.
- [3] Diane J. Cook, Juan C. Augusto, Vikramaditya R. Jakkula, "Ambient intelligence: Technologies, applications, and opportunities, Pervasive and Mobile Computing", Volume 5, Issue 4, 2009.
- [4] Martin, D., Köhl, N. & Satzger, G., "Virtual Sensors", Bus Inf Syst Eng, 2021.
- [5] DEALAB. <https://sites.unica.it/dealab/physical-sensors/>. Acedido a 19 mar 2022.
- [6] Kontakt.io. <https://kontakt.io/what-is-a-beacon/>. Acedido a 19 mar 2022.
- [7] INSIDER. <https://www.businessinsider.com/google-fit>. Acedido a 19 mar 2022.
- [8] ENCYCLOPEDIA.COM. <https://www.encyclopedia.com/sports/sports-fitness-recreation-and-leisure-magazines/sport-performance>. Acedido a 19 mar 2022.
- [9] Michael Kellmann, Laurent Bosquet, Maurizio Bertollo, Aaron J. Coutts, "Recovery and Performance in Sport: Consensus Statement", Journal of Sports Physiology and Performance", 2017.
- [10] CDC. <https://www.thisisant.com/consumer/news-info/tips>. Acedido a 20 mar 2022.
- [11] WHOOP. <https://www.whoop.com/thelocker/heart-rate-recovery/>. Acedido a 20 mar 2022.
- [12] Torrens University Australia. <https://www.torrens.edu.au/blog/why-sports-industry-is-booming-in-2020-which-key-players-driving-growth#.YjdorerP1D8>. Acedido a 20 mar 2022.

- [13] Counterpoint. <https://www.counterpointresearch.com/global-smartwatch-market-2021/>.
Acedido a 20 mar 2022.
- [14] Google Fit. <https://developers.google.com/fit/rest>. Acedido a 23 mar 2022.
- [15] API Console Help. <https://support.google.com/googleapi/answer/7015000?hl=en>. Acedido a 23 mar 2022.
- [16] Google Workspace for developers. <https://developers.google.com/workspace/marketplace/create-gcp-project>. Acedido a 23 mar 2022.
- [17] auth0. <https://auth0.com/intro-to-iam/what-is-oauth-2/>. Acedido a 23 mar 2022.
- [18] Google Identity Plataform. <https://developers.google.com/identity/protocols/oauth2>. Acedido a 23 mar 2022.
- [19]. Idapwiki.com. <https://ldapwiki.com/wiki/Client%20Secret>. Acedido a 23 mar 2022.
- [20] Gogle Identity Plataform. <https://developers.google.com/identity/protocols/oauth2/javascript-implicit-flow>. Acedido a 23 mar 2022.
- [21] Gogle Identity Plataform. <https://developers.google.com/identity/protocols/oauth2#5.-refresh-the-access-token-if-necessary>. Acedido a 23 mar 2022.
- [22] Chrome Web Store. <https://chrome.google.com/webstore/detail/oauth-20-playground/fcjholccjchipkibibepfimlaapdaiih>. Acedido a 23 mar 2022.
- [23] Google Fit. <https://developers.google.com/fit/rest/v1/data-sources>. Acedido a 23 mar 2022.
- [24] Adafruit IO. <https://learn.adafruit.com/adafruit-io-basics-feeds>. Acedido a 23 mar 2022.
- [25] Data Studio Help. <https://support.google.com/datastudio/answer/6283323?hl=en>. Acedido a 23 mar 2022.
- [26] Google Sheets. <https://www.google.com/sheets/about/>. Acedido a 23 mar 2022.
- [27] Data Studio Help. <https://support.google.com/datastudio/answer/7059697?hl=pt-BR#about-chart&zippy=%2Cneste-artigo>. Acedido a 27 mar 2022

